

## PC4 : EXERCICES CORRECTION

**Exercice 1** Après obtention d'une mesure  $z$  d'un paramètre  $\theta$ , la densité de probabilité conditionnelle a posteriori de  $\theta$  est de la forme  $f(\theta|z) = \exp(z - \theta)$ , pour  $z \leq \theta$ .

1. Calculer les estimateurs du risque moyen en valeur absolue, du risque moyen quadratique et du maximum de vraisemblance a posteriori.

Le risque moyen en valeur absolue s'écrit :  $r_{MVA} = E_{\theta} |\theta - \hat{\theta}|$  ce qui s'écrit

$$r_{MVA} = E_{\theta|Z} |\theta - \hat{\theta}| \text{ soit } \int_z^{+\infty} |\theta - \hat{\theta}| f(\theta|Z) d\theta.$$

Pour minimiser ce risque, on cherche  $\hat{\theta}$  tel que  $\frac{\partial}{\partial \hat{\theta}} \int_z^{+\infty} |\theta - \hat{\theta}| \exp(z - \theta) d\theta = 0$ , soit  $\frac{\partial}{\partial \hat{\theta}} \int_z^{\hat{\theta}} |\theta - \hat{\theta}| \exp(z - \theta) d\theta + \frac{\partial}{\partial \hat{\theta}} \int_{\hat{\theta}}^{+\infty} |\theta - \hat{\theta}| \exp(z - \theta) d\theta = 0$  qui se réduit à  $-\frac{\partial}{\partial \hat{\theta}} \int_z^{\hat{\theta}} (\theta - \hat{\theta}) \exp(z - \theta) d\theta + \frac{\partial}{\partial \hat{\theta}} \int_{\hat{\theta}}^{+\infty} (\theta - \hat{\theta}) \exp(z - \theta) d\theta = 0$  soit  $\hat{\theta}$  doit satisfaire  $\int_z^{\hat{\theta}} \exp(z - \theta) d\theta = \int_{\hat{\theta}}^{+\infty} \exp(z - \theta) d\theta$ , soit  $\hat{\theta} = z + \ln(2)$ .

On retrouve ici une propriété de l'estimateur pour le risque moyen en valeur absolue. En effet la médiane associée à la densité exponentielle  $e^{-\theta}$  avec  $\theta \geq 0$  est l'argument de  $\frac{1}{2}$  soit  $\theta = \ln(2)$ . Après décalage de  $z$ , on retrouve bien l'estimateur du risque moyen en v. a.  $\hat{\theta} = z + \ln(2)$ .

Le risque quadratique s'écrit :  $r_{MVA} = E_{\theta} (\theta - \hat{\theta})^2$ . Par le même raisonnement que précédemment,  $\hat{\theta}$  minimisant ce risque doit satisfaire  $\frac{\partial}{\partial \hat{\theta}} \int_z^{+\infty} (\theta - \hat{\theta})^2 \exp(z - \theta) d\theta = 0$  soit  $2 \int_z^{+\infty} (\theta - \hat{\theta}) \exp(z - \theta) d\theta = 0$  soit  $\hat{\theta} \int_z^{+\infty} \exp(z - \theta) d\theta = \int_z^{+\infty} \theta \exp(z - \theta) d\theta$  ou encore  $\hat{\theta} = \int_z^{+\infty} \theta \exp(z - \theta) d\theta$ . On retrouve le résultat classique sur l'estimateur bayésien du risque quadratique, à savoir que  $\hat{\theta}$  est l'espérance a posteriori, qui vaut ici  $z + 1$ .

On retrouve également le résultat classique de correspondance entre l'estimateur du risque moyen quadratique et l'estimateur de la moyenne a posteriori. La moyenne (espérance) associée à la densité  $e^{-\lambda\theta}$  est égale à  $\lambda$ . Dans le cas présent,  $\lambda = 1$ , et après décalage de  $z$ , on retrouve bien l'estimateur de la moyenne a posteriori  $\hat{\theta} = z + 1$ , égal à l'estimateur du risque moyen quadratique.

Pour le maximum de vraisemblance a posteriori, l'estimateur doit maximiser  $f(\theta|z)$  donc maximiser  $(z - \theta)$  avec  $\theta \geq z$  donc  $\hat{\theta} = z$

**Exercice 2** Loi *a priori* de Jeffreys dans le cas gaussien. On considère la suite de variables aléatoires gaussiennes indépendantes de paramètres  $\theta$  et  $\sigma^2$ , où  $\theta$  est une variable aléatoire

1.  $f(z|\theta)$  est la densité d'une loi gaussienne  $\mathcal{N}(\theta, \sigma^2)$   
donc  $f(z|\theta)$  est proportionnelle à  $\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z-\theta)^2}{2\sigma^2}\right)$

2. La vraisemblance s'écrit  $L(\theta; z_1, \dots, z_n) = f(z_1, \dots, z_n | \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z_i - \theta)^2}{2\sigma^2}\right) = \frac{1}{\sqrt{2\pi\sigma^2}^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (z_i - \theta)^2\right)$ .
3. La log-vraisemblance s'écrit alors :  $\ln L(\theta; z_1, \dots, z_n) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (z_i - \theta)^2$ . Ainsi, la matrice d'information de Fisher s'écrit ( $\sigma$  est une constante déterministe) :  $I(\theta) = -E\left(\frac{\partial^2 \ln L}{\partial^2 \theta}\right) = E\left(\frac{n}{\sigma^2}\right) = \frac{n}{\sigma^2}$ .
4. La loi a priori de Jeffreys sur  $\theta$  s'exprime sous la forme  $\pi(\theta) \propto \sqrt{\det(I(\theta))} = \frac{\sqrt{n}}{\sigma}$ .

Dans le cas considéré, la loi a priori de  $\theta$  est la loi uniforme sur un intervalle que l'on choisira grand ( $\sigma$  constante)

**Exercice 3** On considère une variable aléatoire représentant la réussite ou l'échec d'une réalisation. Cette variable, nommée  $X$  dans la suite suit une loi de Bernoulli de paramètre  $\theta$

Le paramètre  $\theta$  est supposé représenter une variable aléatoire de loi *a priori* définie par  $\mathbb{P}(\theta = \theta_1) = p$  et  $\mathbb{P}(\theta = \theta_2) = 1 - p$

1. Loi  $\pi(\theta | Z = z) : \mathbb{P}(Z = 0) = 1 - \theta, \mathbb{P}(Z = 1) = \theta$   

$$\pi(\theta = \theta_1 | Z = 0) = \frac{(1-\theta_1)p}{(1-\theta_1)p + (1-\theta_2)(1-p)}$$

$$\pi(\theta = \theta_1 | Z = 1) = \frac{\theta_1 p}{\theta_1 p + \theta_2 (1-p)}$$

$$\pi(\theta = \theta_2 | Z = 0) = \frac{(1-\theta_2)(1-p)}{(1-\theta_1)p + (1-\theta_2)(1-p)}$$

$$\pi(\theta = \theta_2 | Z = 1) = \frac{\theta_2 (1-p)}{\theta_1 p + \theta_2 (1-p)}$$
;
2. On considère l'estimateur défini par  $T(0) = \mu_1, T(1) = \mu_2$ . Pour  $C(\theta, T) = (\theta - T)^2$  pour  $z = 1$  et  $z = 0$ ,  $\mathbb{E}^\pi[C(\theta, T) | z = 0]$  est égal à  
 $(\theta_1 - \mu_1)^2 \pi(\theta = \theta_1 | Z = 0) + (\theta_2 - \mu_1)^2 \pi(\theta = \theta_2 | Z = 0)$   
 $\mathbb{E}^\pi[C(\theta, T) | z = 1]$  est égal à  
 $(\theta_1 - \mu_2)^2 \pi(\theta = \theta_1 | Z = 1) + (\theta_2 - \mu_2)^2 \pi(\theta = \theta_2 | Z = 1)$   
 $\mathbb{E}^\pi[C(\theta, T) | z = 0] = (\theta_1 - \mu_1)^2 \lambda_1 + (\theta_2 - \mu_1)^2 (1 - \lambda_1)$   
avec  $\lambda_1 = \frac{(1-\theta_1)p}{(1-\theta_1)p + (1-\theta_2)(1-p)}$   
 $\mathbb{E}^\pi[C(\theta, T) | z = 1] = (\theta_1 - \mu_2)^2 \lambda_2 + (\theta_2 - \mu_2)^2 (1 - \lambda_2)$   
avec  $\lambda_2 = \frac{\theta_1 p}{\theta_1 p + \theta_2 (1-p)}$
3. L'estimateur de Bayes associé à ce coût minimise  $\mathbb{E}^\pi[C(\theta, T) | z = 0]$  et  $\mathbb{E}^\pi[C(\theta, T) | z = 1]$ .  
Pour  $\mathbb{E}^\pi[C(\theta, T) | z = 0] = (\theta_1 - \mu_1)^2 \lambda_1 + (\theta_2 - \mu_1)^2 (1 - \lambda_1)$ , l'expression s'écrit  
 $\mathbb{E}^\pi[C(\theta, T) | z = 0] = \lambda(\theta_1^2 + \mu_1^2 - 2\theta_1 \mu_1) + (1 - \lambda)(\theta_2^2 + \mu_1^2 - 2\theta_2 \mu_1)(1 - \lambda)$

$$\bullet = \mu_1^2 - 2(\theta_1\lambda + \theta_2(1-\lambda)\mu_1 + \theta_1^2\lambda + \theta_2^2(1-\lambda))$$

$$\bullet = (\mu_1 - (\theta_1\lambda + \theta_2(1-\lambda)))^2 + f(\theta_1, \theta_2, \lambda)$$

On cherche  $\hat{\mu}_1$  qui minimise cette expression.

On obtient  $\hat{\mu}_1 = \theta_1\lambda_1 + \theta_2(1-\lambda_1)$

Les calculs sont identiques pour  $\mu_2$  et donne  $\hat{\mu}_2 = \theta_1\lambda_2 + \theta_2(1-\lambda_2)$

**Exercice 4** Soit  $Z$  une v.a. telle que  $Z \propto \mathcal{N}(\theta, 1)$  où  $\theta$  est un paramètre qui suit une loi de probabilité  $\mathcal{N}(0, \sigma^2)$  où  $\sigma^2$  est inconnu et fixé. Pour estimer  $\theta$ , on considère la fonction de perte quadratique :  $\mathcal{R}(\theta, a) = (\theta - a)^2$ .

1. La loi de  $\theta|Z = z$  est définie par  $\pi(\theta|Z = z) = \frac{f(Z|\theta)\pi(\theta)}{\int f(Z|t)\pi(t)dt}$  qui est proportionnelle au produit  $\mathcal{N}(\theta, 1)\mathcal{N}(0, \sigma^2)$

Le terme de l'exponentielle s'écrit  $-(z - \theta)^2 - \frac{\theta^2}{\sigma^2}$  et par transformation, on peut montrer que la loi est proportionnelle à  $\mathcal{N}(\frac{\sigma^2 z}{1+\sigma^2}, \frac{\sigma^2}{1+\sigma^2})$  (les autres termes ne dépendent pas de  $\theta$ ).

L'estimateur de Bayes est  $a$  qui minimise  $\int_{\Theta} \mathcal{R}(\theta, a) d\mathbb{P}(\theta|Z = z)$

$a$  doit vérifier :  $\frac{\partial}{\partial a} \int_{\Theta} \mathcal{R}(\theta, a) d\mathbb{P}(\theta|Z = z) = 0$  soit  $\frac{\partial}{\partial a} \int_{\Theta} \mathcal{R}(\theta, a) f(\theta|Z = z) d\theta = 0$

ce qui s'écrit  $\int_{\Theta} (\theta - a) f(\theta|Z = z) d\theta = 0$

on en déduit que  $a = \frac{\int_{\Theta} \theta f(\theta|Z=z) d\theta}{\int_{\Theta} f(\theta|Z=z) d\theta}$ , c'est donc la moyenne de  $f(\theta|Z = z)$  soit  $\frac{\sigma^2 z}{1+\sigma^2}$ . Il faut vérifier que cela correspond bien à un minimum (dérivation).

**Exercice 5** Soit l'estimateur  $\hat{\theta} = \arg \max_{\Theta} \pi(\theta|x) = \arg \min_{\Theta} \left( \frac{\|x - M\theta\|^2}{2\sigma^2} + \frac{\|\theta\|^2}{2\mu^2} \right)$

1. En calculant le gradient de  $\frac{\|x - M\theta\|^2}{2\sigma^2} + \frac{\|\theta\|^2}{2\mu^2}$  et en cherchant la valeur de  $\theta$  qui l'annule, on obtient  $\hat{\theta} = (M^t M + \lambda^2 I)^{-1} M^t x$  avec  $\lambda = \frac{\sigma^2}{\mu^2}$

Il s'agit ensuite de vérifier si cela correspond bien à un minimum.

**Exercice 6** *Loi a posteriori*

1. — Fonction de vraisemblance :

$$L(\theta|t_1, \dots, t_n) = f_{\theta}(t_1, \dots, t_n) = \prod_{i=1}^n f_{\theta}(t_i) = \theta^n \exp\left(-\theta \sum_{i=1}^n t_i\right) \quad (1)$$

— Fonction de log-vraisemblance :

$$\ln L(\theta|t_1, \dots, t_n) = n \ln(\theta) - \theta \sum_{i=1}^n t_i \quad (2)$$

— En calculant les dérivées successives par rapport à  $\theta$ , il vient :

$$\begin{cases} \frac{\partial \ln L(\theta|t_1, \dots, t_n)}{\partial \theta} &= \frac{n}{\theta} - \sum_{i=1}^n t_i \\ \frac{\partial^2 \ln L(\theta|t_1, \dots, t_n)}{\partial \theta^2} &= -\frac{n}{\theta^2} \end{cases} \quad (3)$$

Ainsi,  $\frac{\partial \ln L(\theta|t_1, \dots, t_n)}{\partial \theta} = 0$  équivaut à  $\theta = \frac{n}{\sum_{i=1}^n t_i}$ , et comme  $\frac{\partial^2 \ln L(\theta|t_1, \dots, t_n)}{\partial \theta^2} <$

0 pour tout  $\theta$ , il s'agit d'un maximum.

Ainsi, l'estimateur du maximum de vraisemblance est donné par :  $\hat{\theta}^{(MV)} = \frac{n}{\sum_{i=1}^n t_i}$ .

2. — Fonction de vraisemblance :

$$L(\theta|t_1, \dots, t_n) = \frac{f_\theta(t_1, \dots, t_n)g(\theta)}{f_{T_1, \dots, T_n}(t_1, \dots, t_n)} = \frac{g(\theta)}{f_{T_1, \dots, T_n}(t_1, \dots, t_n)} \prod_{i=1}^n f_\theta(t_i) = \frac{\lambda \theta^n}{f_{T_1, \dots, T_n}(t_1, \dots, t_n)} \exp(-\lambda \theta - \theta \sum_{i=1}^n t_i) \quad (4)$$

— Fonction de log-vraisemblance :

$$\ln L(\theta|t_1, \dots, t_n) = -\ln(f_{T_1, \dots, T_n}(t_1, \dots, t_n)) + \ln(\lambda) + n \ln(\theta) - \lambda \theta - \theta \sum_{i=1}^n t_i \quad (5)$$

— En calculant les dérivées successives par rapport à  $\theta$ , il vient :

$$\begin{cases} \frac{\partial \ln L(\theta|t_1, \dots, t_n)}{\partial \theta} &= \frac{n}{\theta} - \lambda - \sum_{i=1}^n t_i \\ \frac{\partial^2 \ln L(\theta|t_1, \dots, t_n)}{\partial \theta^2} &= -\frac{n}{\theta^2} \end{cases} \quad (6)$$

Ainsi,  $\frac{\partial \ln L(\theta|t_1, \dots, t_n)}{\partial \theta} = 0$  équivaut à  $\theta = \frac{n}{\lambda + \sum_{i=1}^n t_i}$ , et comme  $\frac{\partial^2 \ln L(\theta|t_1, \dots, t_n)}{\partial \theta^2} <$

0 pour tout  $\theta$ , il s'agit d'un maximum.

Ainsi, l'estimateur du maximum a posteriori est donné par :  $\hat{\theta}^{(MV)} = \frac{n}{\lambda + \sum_{i=1}^n t_i}$ .

3.

$$\frac{\hat{\theta}^{(MV)}}{\hat{\theta}^{(MAP)}} = 1 + \frac{\lambda}{\sum_{i=1}^n t_i} \rightarrow_{n \rightarrow \infty} 1. \quad (7)$$

Ainsi, les deux estimateurs sont équivalents pour  $n$  grand.