

PC 3 - CORRECTION

Exercice 1 Estimateur du maximum de vraisemblance

1. Par le fait que les variables sont indépendantes et identiquement distribuées, la vraisemblance s'écrit :

$$L(x_1, \dots, x_n; \theta) = f(X_1 = x_1, \dots, X_n = x_n; \theta) = \prod_{i=1}^n f(X_i = x_i; \theta) = \prod_{i=1}^n \frac{x_i}{\theta} \exp\left(\frac{-x_i}{2\theta}\right) I_{\mathbb{R}_+}(x_i) \quad (1)$$

Ainsi, la Log-vraisemblance s'écrit :

$$\ln L(x_1, \dots, x_n; \theta) = \sum_{i=1}^n \left(\ln(x_i) - \ln(\theta) - \frac{x_i^2}{2\theta} \right) = -n \ln(\theta) + \sum_{i=1}^n (\ln(x_i)) - \frac{1}{2\theta} \sum_{i=1}^n (x_i^2) \quad (2)$$

Calculons les dérivées d'ordre 1 et 2 par rapport à θ de cette expression. On trouve :

$$\begin{cases} \frac{\partial \ln L(x_1, \dots, x_n; \theta)}{\partial \theta} &= -\frac{n}{\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n x_i^2 \\ \frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2} &= \frac{n}{\theta^2} - \frac{1}{\theta^3} \sum_{i=1}^n x_i^2 \end{cases} \quad (3)$$

Ainsi, $\frac{\partial \ln L(x_1, \dots, x_n; \theta)}{\partial \theta} = 0$ équivaut à :

$$\hat{\theta} = \frac{1}{2n} \sum_{i=1}^n x_i^2, \quad (4)$$

et pour cette valeur de θ , on trouve :

$$\frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2} = \frac{-2n^3}{\left[\sum_{i=1}^n x_i^2 \right]^2} \quad (5)$$

Ainsi, la fonction de vraisemblance admet un unique extremum, et il s'agit d'un maximum global. D'où l'estimateur du maximum de vraisemblance suivant :

$$\hat{\theta} = \frac{1}{2n} \sum_{i=1}^n x_i^2. \quad (6)$$

2. Moyenne :

$$E[\hat{\theta}] = E\left[\frac{1}{2n} \sum_{i=1}^n x_i^2\right] = \frac{1}{2n} \sum_{i=1}^n E[x_i^2] = \frac{1}{2n} \sum_{i=1}^n 2\theta = \theta \quad (7)$$

Variance (la troisième égalité provient de l'indépendance des x_i) :

$$\begin{aligned} \text{Var}(\theta) &= \frac{1}{4n^2} \text{Var}\left(\sum_{i=1}^n x_i^2\right) = \frac{1}{4n^2} \sum_{i=1}^n \text{Var}(x_i^2) + \frac{1}{4n^2} \sum_{i=1}^n \sum_{j=1, j \neq i}^n \text{Covar}(x_i^2, x_j^2) = \frac{1}{4n} \text{Var}(x_1^2) + 0 \\ &= \frac{1}{4n} (E[x_1^4] - E[x_1^2]^2) = \frac{1}{4n} (8\theta^2 - 4\theta^2) = \frac{\theta^2}{n} \xrightarrow{n \rightarrow \infty} 0 \end{aligned} \quad (8)$$

Ainsi, l'estimateur est non biaisé et converge vers θ en moyenne quadratique.

3. On a :

$$\begin{cases} E\left[\frac{\partial \ln L(x_1, \dots, x_n; \theta)}{\partial \theta}\right] &= -\frac{n}{\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n E[x_i^2] = -\frac{n}{\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n 2\theta = 0 \\ E\left[\frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2}\right] &= \frac{n}{\theta^2} - \frac{1}{\theta^3} \sum_{i=1}^n E[x_i^2] = \frac{n}{\theta^2} - \frac{1}{\theta^3} \sum_{i=1}^n 2\theta = -\frac{n}{\theta^2} \end{cases} \quad (9)$$

Ainsi, la condition de régularité du théorème de Cramer-Rao est vérifiée, et la matrice d'information de Fisher vaut :

$$F(\theta) = -E\left[\frac{\partial^2 \ln L(x_1, \dots, x_n; \theta)}{\partial \theta^2}\right] = \frac{n}{\theta^2}. \quad (10)$$

Finalement, la borne de Cramer-Rao vaut :

$$BCR(\theta) = F(\theta)^{-1} = \frac{\theta^2}{n}, \quad (11)$$

et $\hat{\theta}$ est un estimateur sans biais atteignant la borne de Cramer-Rao, c'est donc un estimateur efficace.

Exercice 2 Estimation maximum a posteriori

1. La loi a posteriori s'écrit :

$$f(\theta|x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n|\theta)f(\theta)}{f(x_1, \dots, x_n)} = \frac{\left(\prod_{i=1}^n \frac{x_i}{\theta} \exp\left(\frac{-x_i^2}{2\theta}\right) I_{\mathbb{R}^+}(x_i)\right) \left(\frac{\beta^\alpha}{\Gamma(\alpha)} \frac{1}{\theta^{\alpha+1}} \exp\left(\frac{-\beta}{\theta}\right) \mathcal{I}_{\mathbb{R}^+}(\theta)\right)}{f(x_1, \dots, x_n)} \quad (12)$$

2. La loi peut se réécrire :

$$\begin{aligned} f(\theta|x_1, \dots, x_n) &= \frac{\beta^\alpha}{\Gamma(\alpha)} \frac{\left(\prod_{i=1}^n x_i I_{\mathbb{R}^+}(x_i)\right)}{f(x_1, \dots, x_n)} \times \left(\frac{1}{\theta^n} \exp\left(\frac{-1}{2\theta} \sum_{i=1}^n x_i^2\right)\right) \left(\frac{1}{\theta^{\alpha+1}} \exp\left(\frac{-\beta}{\theta}\right) \mathcal{I}_{\mathbb{R}^+}(\theta)\right) \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \frac{\left(\prod_{i=1}^n x_i I_{\mathbb{R}^+}(x_i)\right)}{f(x_1, \dots, x_n)} \times \left(\frac{1}{\theta^{n+\alpha+1}} \exp\left(\frac{-1}{\theta} \left(\beta + \frac{1}{2} \sum_{i=1}^n x_i^2\right)\right) \mathcal{I}_{\mathbb{R}^+}(\theta)\right), \end{aligned} \quad (13)$$

ce qui peut se mettre sous la forme d'une loi inverse-gamma avec $\alpha' = n + \alpha$, et $\beta' = \beta + \frac{1}{2} \sum_{i=1}^n x_i^2$.

De plus, comme $\alpha > 0$ et $\beta > 0$, on a également $\alpha' > 0$ et $\beta' > 0$.

3. La log Vraisemblance s'écrit :

$$\ln f(\theta|x_1, \dots, x_n) = C - (\alpha' + 1) \ln(\theta) - \frac{\beta'}{\theta}, \quad (14)$$

où C est une constante indépendante de θ .

Ainsi :

$$\frac{\partial \ln f(\theta|x_1, \dots, x_n)}{\partial \theta} = -\frac{\alpha' + 1}{\theta} + \frac{\beta'}{\theta^2} \quad (15)$$

Cette dérivée s'annule en l'unique valeur $\theta = \frac{\beta'}{\alpha' + 1}$, valeur pour laquelle on a :

$$\ln f(\theta|x_1, \dots, x_n) = C - (\alpha' + 1) \left(\ln\left(\frac{\beta'}{\alpha' + 1}\right) + 1 \right). \quad (16)$$

De plus, sur l'intervalle $[0; \infty]$ la fonction log-vraisemblance est continue, et $\lim_{\theta \rightarrow 0} \ln f(\theta|x_1, \dots, x_n) = -\infty$, et $\lim_{\theta \rightarrow +\infty} \ln f(\theta|x_1, \dots, x_n) = -\infty$.

Ainsi, la fonction croît sur l'intervalle $]-\infty; \frac{\beta'}{\alpha' + 1}[$, et décroît sur l'intervalle $[\frac{\beta'}{\alpha' + 1}; \infty[$. En particulier, l'extremum calculé est un maximum.

4. Compte-tenu de ce qui précède, l'expression de l'estimateur au sens du maximum a posteriori s'écrit :

$$\hat{\theta}_{MAP} = \frac{\beta'}{\alpha' + 1} = \frac{\beta + \frac{1}{2} \sum_{i=1}^n x_i^2}{\alpha + n + 1}. \quad (17)$$

5. Comme $\hat{\theta}_{MV} = \frac{1}{2n} \sum_{i=1}^n x_i^2$ (cf. Exercice 1), on a :

$$\hat{\theta}_{MAP} = \frac{\beta + n\hat{\theta}_{MV}}{\alpha + n + 1} \quad (18)$$

De plus, comme $\lim_{n \rightarrow \infty} \theta_{MV} = \theta$ (cf. Exercice 1), on a :

$$\lim_{n \rightarrow \infty} \hat{\theta}_{MAP} = \theta. \quad (19)$$

L'estimateur $\hat{\theta}_{MAP}$ se comporte donc comme $\hat{\theta}_{MV}$ lorsque $n \rightarrow \infty$. Lorsque le nombre d'observations devient très important, on fait confiance à ces observations et l'influence de la loi a priori devient négligeable.

Exercice 3 Algorithme EM et mélange de gaussiennes

Il s'agit d'appliquer au cas d'espèce les équations suivantes (vues en cours) :

— Etape (E) - Expectation - Calcul des probabilités *a posteriori* (permettant d'écrire l'espérance en Z) :

$$\tilde{p}_{ij,m} = \frac{f_j(x_i; \theta_{m-1}) p_j(\theta_{m-1})}{\sum_{k=1}^K f_k(x_i; \theta_{m-1}) p_k(\theta_{m-1})}. \quad (20)$$

— Etape (M) - Maximization - Maximisation de la vraisemblance :

$$\theta_m = \arg \max_{\theta \in \Theta} \left\{ \sum_{i=1}^n \sum_{j=1}^K \tilde{p}_{ij,m} \ln [f_j(x_i; \theta) p_j(\theta)] \right\}. \quad (21)$$

L'étape (E) s'écrit pour tout $i \in \{1, \dots, n\}$:

$$\begin{cases} \tilde{p}_{i,1,m} &= \frac{f(x_i; \hat{\mu}_{1,m-1}, \hat{\sigma}_{1,m-1}) \hat{\lambda}_{m-1}}{f(x_i; \hat{\mu}_{1,m-1}, \hat{\sigma}_{1,m-1}) \hat{\lambda}_{m-1} + f(x_i; \hat{\mu}_{2,m-1}, \hat{\sigma}_{2,m-1}) (1 - \hat{\lambda}_{m-1})} \\ \tilde{p}_{i,2,m} &= 1 - \tilde{p}_{i,1,m} = \frac{f(x_i; \hat{\mu}_{2,m-1}, \hat{\sigma}_{2,m-1}) (1 - \hat{\lambda}_{m-1})}{f(x_i; \hat{\mu}_{1,m-1}, \hat{\sigma}_{1,m-1}) \hat{\lambda}_{m-1} + f(x_i; \hat{\mu}_{2,m-1}, \hat{\sigma}_{2,m-1}) (1 - \hat{\lambda}_{m-1})} \end{cases}. \quad (22)$$

où $f(\cdot; \mu, \sigma)$ est la densité de probabilité d'une loi gaussienne de moyenne μ et d'écart-type σ .

L'étape (M) consiste à trouver le vecteur $\theta = (\lambda, \mu_1, \sigma_1, \mu_2, \sigma_2)$ qui maximise le terme suivant :

$$\mathcal{L}(\theta = (\lambda, \mu_1, \sigma_1, \mu_2, \sigma_2)) = \sum_{i=1}^n \tilde{p}_{i,1,m} \ln [f(x_i; \mu_1, \sigma_1) \lambda] + \tilde{p}_{i,2,m} \ln [f(x_i; \mu_2, \sigma_2) (1 - \lambda)] \quad (23)$$

Le calcul consiste alors à résoudre les équations suivantes :

$$\frac{\partial \mathcal{L}(\theta)}{\partial \lambda} = 0 \quad \frac{\partial \mathcal{L}(\theta)}{\partial \mu_1} = 0 \quad \frac{\partial \mathcal{L}(\theta)}{\partial \sigma_1} = 0 \quad \frac{\partial \mathcal{L}(\theta)}{\partial \mu_2} = 0 \quad (24)$$

afin de déterminer le vecteur de paramètres $\hat{\theta}_m = (\hat{\lambda}_m, \hat{\sigma}_{1,m}, \hat{\mu}_{1,m}, \hat{\mu}_{2,m}, \hat{\sigma}_{2,m})$ à l'issue de l'itération m .

Les calculs de dérivées nous donnent :

$$\begin{cases} \frac{\partial \mathcal{L}(\theta)}{\partial \lambda} = \sum_{i=1}^n \tilde{p}_{i,1,m} \frac{1}{\lambda} - \sum_{i=1}^n \tilde{p}_{i,2,m} \frac{1}{1-\lambda} \\ \frac{\partial \mathcal{L}(\theta)}{\partial \mu_1} = \sum_{i=1}^n \tilde{p}_{i,1,m} \frac{(x_i - \mu_1)}{\sigma_1^2} \\ \frac{\partial \mathcal{L}(\theta)}{\partial \sigma_1} = \sum_{i=1}^n \tilde{p}_{i,1,m} \left(\frac{-1}{\sigma_1} + \frac{(x_i - \mu_1)^2}{\sigma_1^3} \right) \\ \frac{\partial \mathcal{L}(\theta)}{\partial \mu_2} = \sum_{i=1}^n \tilde{p}_{i,2,m} \frac{(x_i - \mu_2)}{\sigma_2^2} \\ \frac{\partial \mathcal{L}(\theta)}{\partial \sigma_2} = \sum_{i=1}^n \tilde{p}_{i,2,m} \left(\frac{-1}{\sigma_2} + \frac{(x_i - \mu_2)^2}{\sigma_2^3} \right) \end{cases}. \quad (25)$$

D'où la solution de l'équation (24) :

$$\left\{ \begin{array}{l} \hat{\lambda}_m = \frac{\sum_{i=1}^n \tilde{p}_{i,1,m}}{\sum_{i=1}^n \tilde{p}_{i,1,m} + \sum_{i=1}^n \tilde{p}_{i,2,m}} \\ \hat{\mu}_{1,m} = \frac{\sum_{i=1}^n \tilde{p}_{i,1,m} x_i}{\sum_{i=1}^n \tilde{p}_{i,1,m}} \\ \hat{\sigma}_{1,m} = \sqrt{\frac{\sum_{i=1}^n \tilde{p}_{i,1,m} (x_i - \hat{\mu}_{1,m})^2}{\sum_{i=1}^n \tilde{p}_{i,1,m}}} \\ \hat{\mu}_{2,m} = \frac{\sum_{i=1}^n \tilde{p}_{i,2,m} x_i}{\sum_{i=1}^n \tilde{p}_{i,2,m}} \\ \hat{\sigma}_{2,m} = \sqrt{\frac{\sum_{i=1}^n \tilde{p}_{i,2,m} (x_i - \hat{\mu}_{2,m})^2}{\sum_{i=1}^n \tilde{p}_{i,2,m}}} \end{array} \right. . \quad (26)$$

Remarquons enfin que l'expression de $\hat{\lambda}_m$ peut être simplifiée. En effet, pour tout $i \in \{1, \dots, n\}$, on a $\tilde{p}_{i,1,m} + \tilde{p}_{i,2,m} = 1$ (cf. equation (22)). Ainsi, il vient finalement : $\hat{\lambda}_m = \frac{1}{n} \sum_{i=1}^n \tilde{p}_{i,1,m}$.